Detección de fibrilación auricular a partir de la serie RR

Informe de avances: pre-procesamiento y extracción de características

[COMPLETAR: integrantes]
Procesamiento de Señales e Imágenes Biomédicas (16.63) – ITBA

Octubre de 2026

Resumen

Se presenta el avance del pipeline para detectar fibrilación auricular (FA) en registros Holter de 24 h de la base SHDB-AF sin usar aprendizaje automático. Se describen la selección de registros, la inspección espectral, el filtrado, la detección de segmentos ruidosos, la detección de QRS con Pan-Tompkins, la construcción y corrección de la serie RR, la segmentación en ventanas y la extracción de características temporales, de irregularidad y espectrales. Los resultados preliminares corresponden al registro 001 **[COMPLETAR: y a los registros elegidos]**.

1 Introducción

La FA es una taquiarritmia supraventricular con activación auricular descoordinada. En el ECG se caracteriza por intervalos R-R irregulares, ausencia de ondas P repetitivas y actividad auricular irregular [3]. El primer rasgo permite detectar FA solo a partir de la serie RR, lo que justifica el enfoque de este trabajo. La guía de 2014 fue actualizada por la de 2023 [4].

El objetivo es construir un detector sin aprendizaje automático: características calculadas por ventana y umbrales elegidos sobre un grupo de sujetos y evaluados sobre otro.

2 Base de datos

Se usa SHDB-AF [1, 2]: 128 registros Holter de 24 h de 127 pacientes japoneses con FA paroxística. Cada registro tiene dos derivaciones (CC5 y NASA), grabadas a 125 Hz con un Holter Fukuda y remuestreadas a 200 Hz. Los encabezados de los archivos confirman $f_s = 200$ Hz y 2 canales (por ejemplo, el registro 001 tiene 17 220 000 muestras, 23,9 h).

Por registro hay cuatro archivos: `.hea` (encabezado), `.dat` (señal), `.qrs` (picos R detectados automáticamente con *epltd*, una implementación de Pan-Tompkins) y `.atr` (anotaciones de ritmo latido a latido hechas a mano por un cardiólogo). El `.dat` es la entrada del pipeline; el `.qrs` se usa solo para validar la detección de QRS y el `.atr` solo como etiqueta, nunca como entrada del detector.

3 Metodología

El código está en el repositorio del grupo (carpeta `codigo/`); todos los parámetros están centralizados en `config.py`.

3.1 Etapa 0: selección de registros

De los 128 registros, 98 tienen anotaciones de ritmo (`seleccion.py`). Se guarda el `Subject_ID` de cada uno para que la partición train/test se haga por sujeto [5]. Ninguno de los 98 tiene marcapasos

durante el Holter. El pipeline se aplica a los 98 registros, de a 4 en paralelo (`correr_todo.py`). **[COMPLETAR: registros que fallaron, si hubo]**

3.2 Etapa 1: carga por tramos

Cada registro ocupa ∼69 MB y $17{,}2 \times 10^6$ muestras por canal. Se lee de a tramos de 30 min con 5 s de solape (para no perder latidos en los bordes) y se procesa el canal ECG1. La señal procesada no se guarda: solo los resultados (posiciones de R, serie RR, características).

3.3 Etapa 2: inspección espectral

Se estima la densidad espectral de potencia con el método de Welch [6] (ventana de Hann de 10 s, 50 % de solape, resolución 0,1 Hz) en 6 tramos de 5 min repartidos en las 24 h.

3.4 Etapa 3: filtrado y detección de ruido

Se aplica un pasa-banda Butterworth de 0,5 a 40 Hz con *filtfilt* (fase cero). El corte inferior elimina la deriva de línea de base; con filtrado de fase cero un corte de hasta 0,67 Hz no distorsiona el ECG [7]. El corte superior atenúa el ruido muscular y el contenido por encima de 62,5 Hz. No se agrega notch (ver Sección 4.1).

Para detectar ruido se divide el registro en ventanas de 10 s y se calculan dos índices de calidad [8, 9]:

- **bSQI**: acuerdo entre dos detectores de QRS distintos (Pan-Tompkins y `xqrs` de la librería wfdb), $\text{bSQI} = \frac{VP}{VP+FN+FP}$ con tolerancia de 150 ms. Si el ECG está limpio, ambos detectores coinciden.
- **kSQI**: curtosis del ECG filtrado. Un ECG limpio es impulsivo (curtosis > 5); el ruido tiende a una distribución gaussiana (curtosis ≈ 3).

Una ventana se marca como ruidosa si $\text{bSQI} < 0{,}8$ o $\text{kSQI} < 5$. El umbral de bSQI es el que usan Chocron et al. [11] para excluir ventanas de 60 latidos en la detección de FA, tomado de Behar et al. [10]; el de kSQI corresponde al valor por encima del cual un ECG sinusal se considera limpio [12]. **[COMPLETAR: ajuste de umbrales si se hizo]**

3.5 Etapa 4: limpieza con filtrado adaptativo (plan, sin implementar)

Por ahora las ventanas ruidosas (etapa 3) se excluyen, que es lo que hacen trabajos de detección de FA a partir de la serie RR [11]. Como alternativa se plantea un mejorador adaptativo de línea (ALE) [13, 18] aplicado solo a esas ventanas, para recuperar las que se puedan.

Estructura. El ALE es un cancelador de una sola entrada: la referencia es la propia señal retrasada Δ muestras, y un filtro FIR adaptativo de L coeficientes predice la componente de la señal que sigue correlacionada después de Δ; el ruido que se decorrelaciona en ese retardo queda en el error [13]. Thakor y Zhu [18] aplicaron estructuras adaptativas al ECG para cancelar ruido muscular y artefactos de movimiento, y una variante con referencia sincronizada con los QRS a la detección de FA.

Limitación para FA. El QRS tiene una duración del mismo orden que la correlación del ruido muscular, y en FA el RR es irregular, por lo que no puede usarse un retardo de un latido. La alternativa con referencia sincronizada a las R [18, 16] depende de detectar bien las R, que es justamente lo que falla en las ventanas ruidosas. Esta limitación se evaluará antes de adoptar el ALE.

Parámetros. No hay en la literatura valores fijos de Δ, L y μ para este problema; en filtrado adaptativo de ECG se eligen por búsqueda sobre datos de prueba [16]. El plan es:

Tabla 1: Diseño propuesto del ALE y fuente de cada parámetro.

Parámetro	Valor o criterio	Fuente
Estructura	ALE de una entrada, referencia = señal retrasada Δ	[13]
Algoritmo	LMS normalizado (NLMS), pesos iniciales en cero	[16]
Paso μ	Estabilidad: $0 < \mu < 2$ (NLMS); constante de tiempo $\tau \approx 1/(2\mu\lambda)$. Búsqueda en 8 valores logarítmicos entre 0,0005 y 0,1	[15, 14, 16]
Coeficientes L	Búsqueda en grilla (Fotiadou: 50 a 800 a 500 Hz; escalado a 200 Hz: 20 a 320)	[16]
Retardo Δ	Mayor que el ancho de la autocorrelación del ruido, medido en los registros `ma` y `em` de la NSTDB; menor que el de la autocorrelación del QRS	[13, 17]
Dónde se aplica	Solo en ventanas con bSQI $<$ 0,8 o kSQI $<$ 5	[11, 12]
Datos de prueba	ECG limpio + ruido `ma` y `em` de la MIT-BIH NSTDB a 24, 18, 12, 6, 0 y -6 dB	[17]
Criterio de éxito	Mejora de Se y VPP de la detección de QRS (EC57) y recuperación de bSQI $\geq$ 0,8; si no mejora, la ventana se excluye	[23, 11]

Para controlar el sesgo, se reportará qué proporción de ventanas de FA y de no-FA queda excluida o recuperada.

3.6 Etapa 5: detección de QRS

Se usa el preprocesado de Pan y Tompkins [19], diseñado para 200 Hz: pasa-banda de 5–15 Hz, derivada de 5 puntos, cuadrado e integración en ventana de 150 ms. Los filtros originales de coeficientes enteros se eligieron para operar en tiempo real en un microprocesador [19, 20]; como el procesamiento es *offline*, se reemplazan por filtros Butterworth de orden 2 aplicados con *filtfilt* (fase cero), como en Elgendi et al. [21], que usaron un Butterworth de segundo orden para comparar bandas de paso en la detección de QRS sobre MIT/BIH, y en línea con implementaciones de referencia que usan Butterworth de orden 1–2 para esta etapa [22]. Con fase cero no hay retardos que compensar.

Las reglas de decisión siguen la versión optimizada de Hamilton y Tompkins [20], que compararon cuantitativamente distintas reglas sobre la base MIT/BIH: niveles de QRS y de ruido estimados con la mediana de los últimos 8 picos (el mejor de los estimadores evaluados), umbral $DT = NPL + 0{,}1825\,(QRSPL - NPL)$, período refractario de 200 ms, búsqueda hacia atrás con la mitad del umbral si no hubo QRS en 1,5 veces la mediana de los últimos 8 RR, y descarte de ondas T entre 200 y 360 ms si la derivada máxima es menor a la mitad de la del QRS previo. Cada R se ubica en el máximo de |ECG| en $\pm$100 ms alrededor de la detección.

La detección se valida contra el `.qrs` con la norma ANSI/AAMI EC57 [23]: tolerancia de 150 ms, sensibilidad $Se = \frac{VP}{VP+FN}$ y valor predictivo positivo $VPP = \frac{VP}{VP+FP}$, solo dentro del tramo que cubre la referencia. Como el `.qrs` fue generado por *epltd*, que implementa el mismo algoritmo de Hamilton y Tompkins, la referencia no es independiente: un acuerdo alto valida la implementación, no la detección en sí. Como referencia, Hamilton y Tompkins reportan $Se = 99{,}69\,\%$ y $VPP = 99{,}77\,\%$ en MIT/BIH [20].

3.7 Etapa 6: serie RR y corrección

Se calcula $RR_k = t_{k+1} - t_k$ y cada intervalo se marca como válido o inválido, sin borrarlo (para conservar la base temporal):

- **fuera de rango**: $RR < 0{,}25$ s (falso QRS) o $RR > 2{,}5$ s (QRS perdido);
- **ruido**: el intervalo cae en una ventana ruidosa (etapa 3);
- **ectópico**: latido ectópico aislado y su pausa compensatoria, con el criterio de Dash et al. [24]: RR_i/RR_{i-1} en el percentil 1, RR_{i+1}/RR_i en el percentil 99 y RR_{i+1}/RR_{i+2} por encima del percentil 25. Dash et al. reportan que remover ectópicos aislados sube la especificidad de 69,4 % a 91,2 %;
- **transición**: el intervalo cruza un cambio de ritmo.

No se descartan intervalos por ser irregulares, ya que la irregularidad es justamente lo que caracteriza a la FA. Las ideas de prefiltrado de la serie RR siguen a PhysioZoo [25], la herramienta usada para anotar SHDB-AF.

3.8 Etapa 7: ventanas

La serie RR se divide en ventanas de 60 intervalos consecutivos sin solape, el largo usado en el benchmark de SHDB-AF [1]. En la literatura se usan desde 8 [26] y 12 [27] hasta 128 latidos [24]. Se conservan solo las ventanas con una única etiqueta (FA o no-FA) y al menos 90 % de intervalos válidos. Flúter y otras taquicardias auriculares se excluyen. **[COMPLETAR: comparación 60 vs 128 latidos]**

3.9 Etapa 8: características por ventana

Sobre los intervalos válidos de cada ventana se calculan:

- **Temporales** [28]: media RR, SDNN y RMSSD.
- **Irregularidad** [24, 27]: RMSSD normalizado por la media (nRMSSD), *turning point ratio* (TPR, fracción de máximos y mínimos locales; vale $\approx 2/3$ en una serie aleatoria), entropía de Shannon del histograma de RR (16 bins, sin los 8 RR más largos ni los 8 más cortos, normalizada a $[0, 1]$) y entropía muestral ($m = 2$, $r = 0{,}2\,\sigma$).
- **Espectrales**: potencia relativa en LF (0,04–0,15 Hz) y HF (0,15–0,4 Hz) y cociente LF/HF con el periodograma de Lomb [30], que no requiere muestras equiespaciadas. El Task Force recomienda registros de 5 min para el análisis espectral de corto plazo y al menos ∼2 min para LF [28, 29]; con ventanas de ∼1 min, LF no es confiable y en FA estas bandas no reflejan modulación autonómica. Se reportan como medidas de irregularidad. Como comparación se plantea una PSD paramétrica AR (Yule-Walker, orden por AIC/BIC [31]). **[COMPLETAR: AR si se implementa]**

4 Resultados preliminares

Los resultados corresponden al registro 001: 809 min de FA seguidos de 626 min de ritmo no-FA, sin marcapasos. **[COMPLETAR: agregar los demás registros]**

4.1 Espectro

La Figura 1 muestra la PSD. El 99,8 % de la potencia cae entre 0,5 y 40 Hz. Se observan dos pozos: en 50 Hz, que indica que el Holter ya aplica un notch de red, y en 75 Hz, que es el reflejo de ese notch por el remuestreo de 125 a 200 Hz ($125 - 50 = 75$ Hz). Por el mismo motivo, el contenido por encima de 62,5 Hz es un artefacto del remuestreo (0,08 % de la potencia), que el pasa-bajos de 40 Hz elimina. No hace falta agregar un notch.

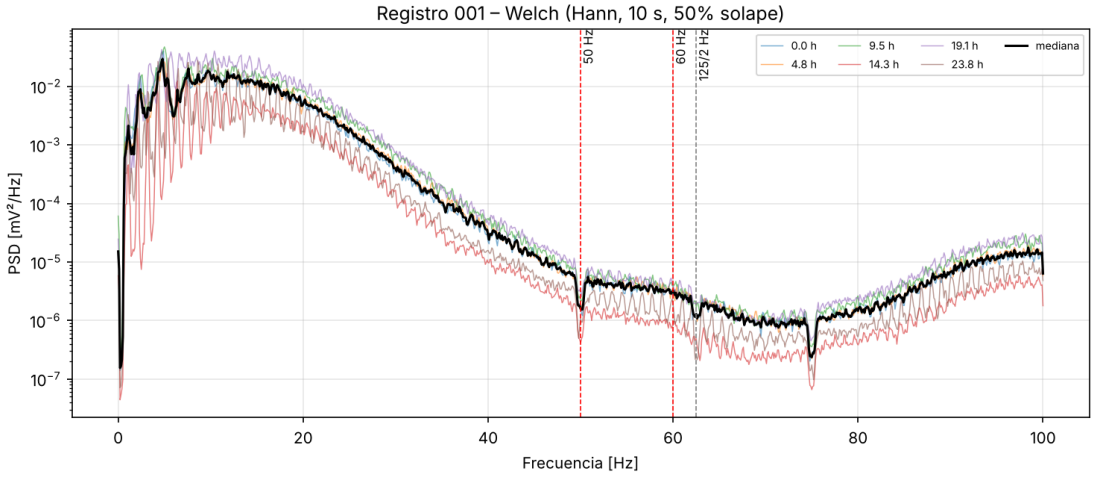


Figura 1: PSD de Welch del registro 001 en 6 tramos de 5 min y su mediana. Líneas: 50, 60 y 62,5 Hz.

4.2 Filtrado y ruido

La Figura 2 muestra el efecto del pasa-banda. En el registro 001 ninguna de las 8610 ventanas de 10 s se marcó como ruidosa: el bSQI mínimo fue 0,90 y el kSQI mínimo 6,05 (Figura 3). Los umbrales todavía deben ponerse a prueba en registros con ruido. **[COMPLETAR: resultados en otros registros]**

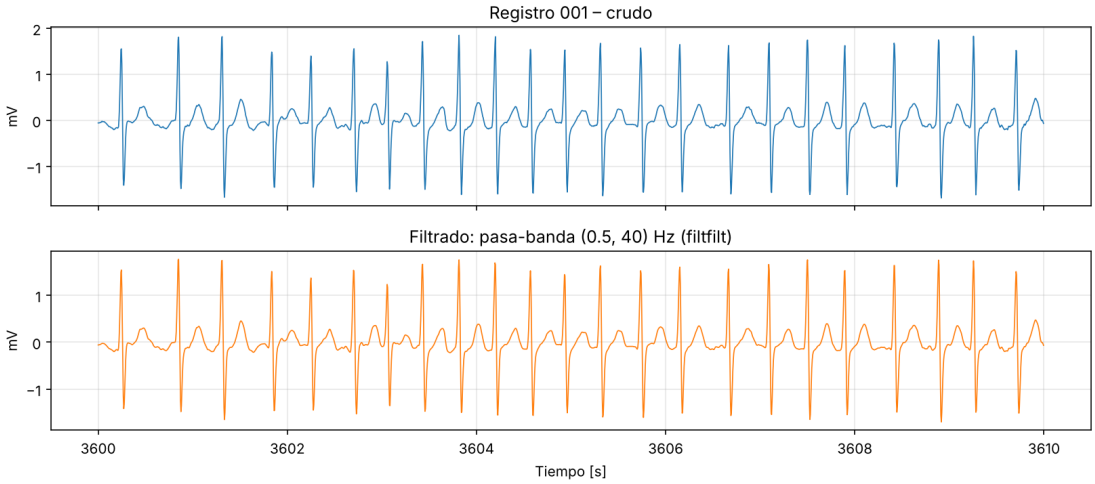


Figura 2: ECG crudo (arriba) y filtrado con pasa-banda de 0,5–40 Hz (abajo).

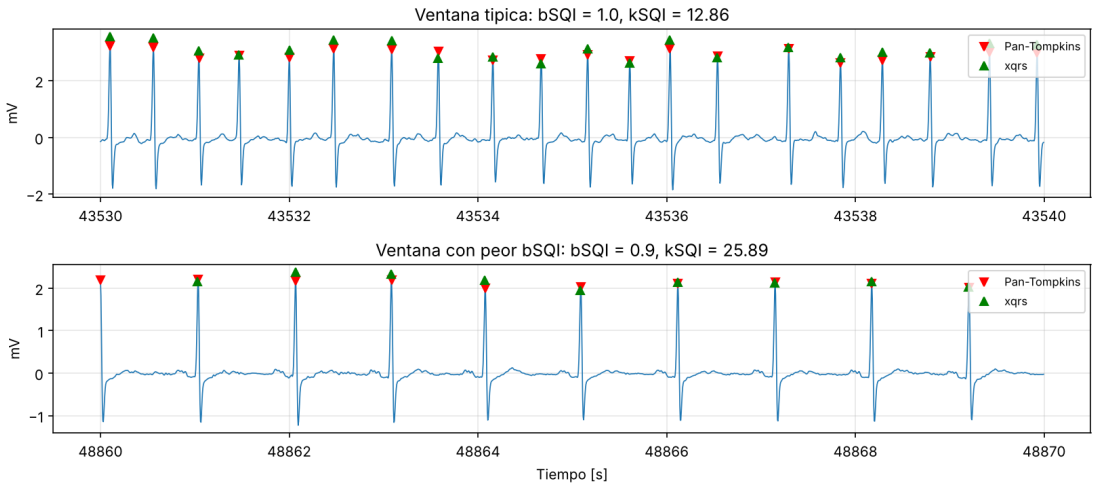


Figura 3: Ventana típica y ventana de peor bSQI, con las detecciones de Pan-Tompkins y `xqrs`. El bSQI de 0,9 se debe a un latido en el borde de la ventana, no a ruido.

4.3 Detección de QRS

Tabla 2: Validación de Pan-Tompkins contra el `.qrs` (tolerancia 150 ms).

Registro	VP	FN	FP	Se (%)	VPP (%)
001	143 768	0	0	100,00	100,00
[COMPLETAR:]					

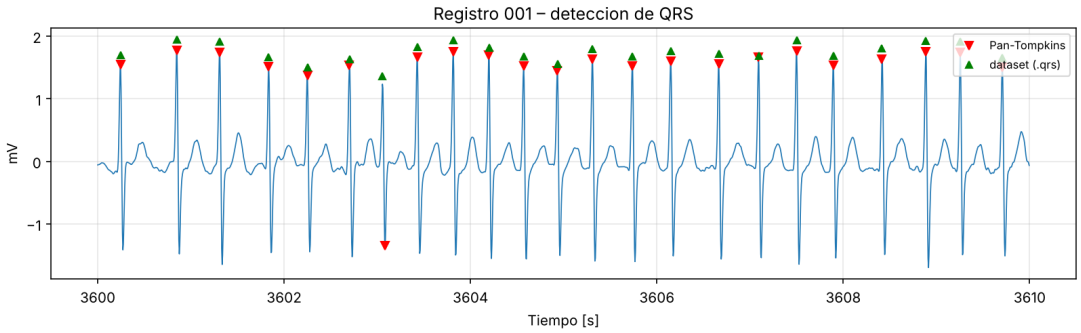


Figura 4: Detecciones propias y del dataset sobre 10 s del registro 001.

4.4 Serie RR

El registro 001 tiene 143 786 intervalos, de los cuales el 99,6 % son válidos: 1 fuera de rango, 516 marcados como ectópicos y 1 en la transición de ritmo. En la Figura 5 se ve el cambio de FA (RR cortos, ≈0,45 s, y muy dispersos) a no-FA (RR ≈0,9 s y ordenados). Parte de los intervalos marcados como ectópicos cae dentro de la FA. **[COMPLETAR: comparación con y sin remoción de ectópicos]**

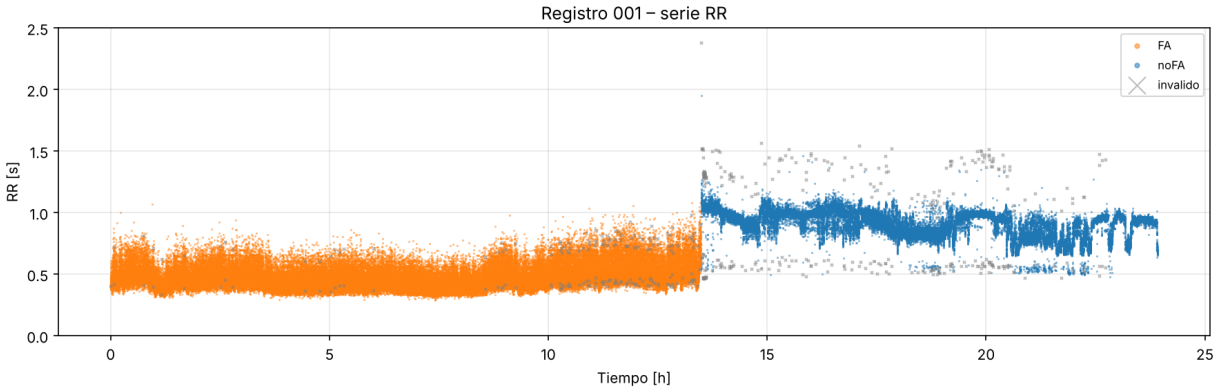


Figura 5: Serie RR de las 24 h del registro 001. Naranja: FA; azul: no-FA; gris: intervalos inválidos.

4.5 Características

Se obtuvieron 2389 ventanas de 60 latidos (1702 de FA y 687 de no-FA). La Tabla 3 y la Figura 6 muestran que las medidas de irregularidad separan bien ambas clases: la mediana de nRMSSD es 0,20 en FA y 0,04 en no-FA, y la de TPR 0,58 y 0,42, consistentes con los umbrales de Dash et al. (nRMSSD $>$ 0,1; TPR entre 0,54 y 0,77) [24]. LF/HF casi no separa, como se esperaba con ventanas cortas.

Tabla 3: Mediana de cada característica por clase (registro 001).

Característica	no-FA	FA
Media RR (s)	0,925	0,466
SDNN (s)	0,043	0,072
RMSSD (s)	0,033	0,094
nRMSSD	0,037	0,202
TPR	0,417	0,583
Shannon	0,836	0,901
SampEn	1,19	1,95
LF (relativa)	0,172	0,222
HF (relativa)	0,349	0,503
LF/HF	0,543	0,449

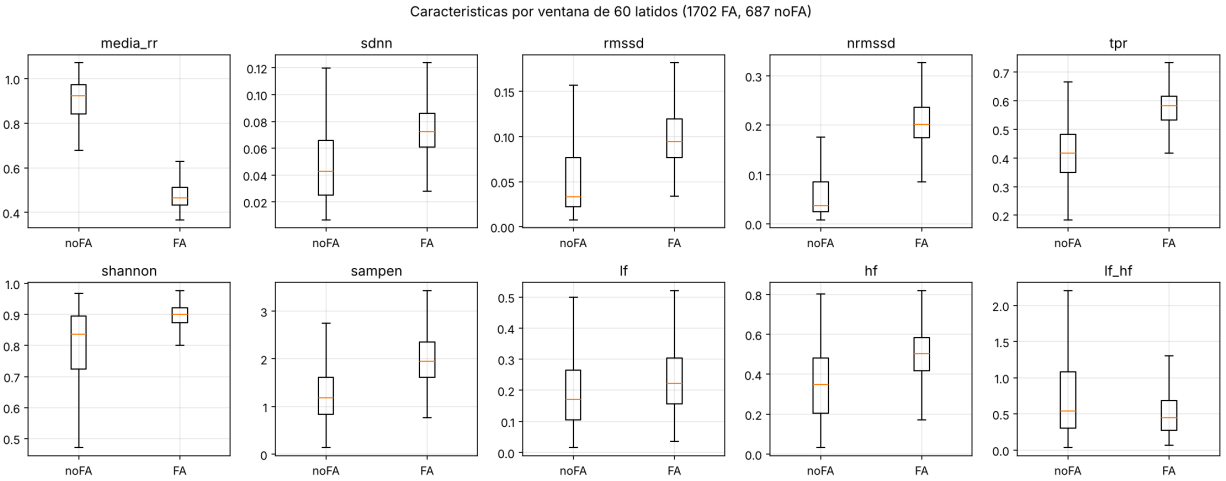


Figura 6: Distribución de cada característica por clase (sin valores atípicos).

5 Limitaciones y próximos pasos

- Los resultados son de un solo registro: falta procesar los 98 registros anotados.
- Los umbrales de ruido no se probaron en registros ruidosos, y el ALE (etapa 4) está pendiente.
- La regla de ectópicos marca algunos intervalos dentro de la FA; hay que evaluar su efecto.
- Las ventanas de un mismo sujeto no son independientes: la estadística (etapa 9) se hará con valores agregados por sujeto y con corrección por comparaciones múltiples.
- Etapa 9: curva ROC y AUC por característica, umbral elegido en un grupo de sujetos (train) y evaluado en otro (test), con sensibilidad y especificidad.

Referencias

[1] K. Tsutsui, S. Biton Brimer, N. Ben-Moshe, et al., "SHDB-AF: a Japanese Holter ECG database of atrial fibrillation," *Scientific Data*, vol. 12, 2025. https://doi.org/10.1038/s41597-025-04777-4

[2] SHDB-AF v1.0.1, PhysioNet. https://physionet.org/content/shdb-af/1.0.1/

[3] C. T. January, L. S. Wann, J. S. Alpert, et al., "2014 AHA/ACC/HRS guideline for the management of patients with atrial fibrillation," *J. Am. Coll. Cardiol.*, vol. 64, no. 21, pp. e1–e76, 2014. https://doi.org/10.1016/j.jacc.2014.03.022

[4] J. A. Joglar, M. K. Chung, et al., "2023 ACC/AHA/ACCP/HRS guideline for the diagnosis and management of atrial fibrillation," *Circulation*, vol. 149, 2024. **[COMPLETAR: verificar cita]**

[5] P. de Chazal, M. O'Dwyer, R. B. Reilly, "Automatic classification of heartbeats using ECG morphology and heartbeat interval features," *IEEE Trans. Biomed. Eng.*, vol. 51, no. 7, pp. 1196–1206, 2004. https://doi.org/10.1109/TBME.2004.827359

[6] P. D. Welch, "The use of fast Fourier transform for the estimation of power spectra," *IEEE Trans. Audio Electroacoust.*, vol. 15, no. 2, pp. 70–73, 1967. https://doi.org/10.1109/TAU.1967.1161901

[7] P. Kligfield, L. S. Gettes, J. J. Bailey, et al., "Recommendations for the standardization and interpretation of the electrocardiogram: Part I," *Circulation*, vol. 115, pp. 1306–1324, 2007. https://doi.org/10.1161/CIRCULATIONAHA.106.180200

[8] Q. Li, R. G. Mark, G. D. Clifford, "Robust heart rate estimation from multiple asynchronous noisy sources using signal quality indices and a Kalman filter," *Physiol. Meas.*, vol. 29, pp. 15–32, 2008. https://doi.org/10.1088/0967-3334/29/1/002

[9] G. D. Clifford, J. Behar, Q. Li, I. Rezek, "Signal quality indices and data fusion for determining clinical acceptability of electrocardiograms," *Physiol. Meas.*, vol. 33, pp. 1419–1433, 2012. https://doi.org/10.1088/0967-3334/33/9/1419

[10] J. Behar, J. Oster, Q. Li, G. D. Clifford, "ECG signal quality during arrhythmia and its application to false alarm reduction," *IEEE Trans. Biomed. Eng.*, vol. 60, no. 6, pp. 1660–1666, 2013. https://doi.org/10.1109/TBME.2013.2240452

[11] A. Chocron, R. Efraim, F. Mandel, et al., J. A. Behar, "Digital biomarkers and artificial intelligence for mass diagnosis of atrial fibrillation in a population sample at risk of sleep disordered breathing," arXiv:2007.14686, 2020. https://arxiv.org/abs/2007.14686

[12] Z. Zhao, Y. Zhang, "SQI quality evaluation mechanism of single-lead ECG signal based on simple heuristic fusion and fuzzy comprehensive evaluation," *Front. Physiol.*, vol. 9, 727, 2018. https://doi.org/10.3389/fphys.2018.00727

[13] B. Widrow, J. R. Glover, J. M. McCool, et al., "Adaptive noise cancelling: principles and applications," *Proc. IEEE*, vol. 63, no. 12, pp. 1692–1716, 1975. https://doi.org/10.1109/PROC.1975.10036

[14] Naval Ocean Systems Center, "Adaptive noise cancelling and enhancement of a sinusoid in uncorrelated noise," Technical Report 184, 1977. https://apps.dtic.mil/sti/pdfs/ADA050313.pdf

[15] S. Haykin, *Adaptive Filter Theory*, 4.ª ed. Upper Saddle River, NJ: Prentice Hall, 2002.

[16] E. Fotiadou, J. O. E. H. van Laar, S. G. Oei, R. Vullings, "Enhancement of low-quality fetal electrocardiogram based on time-sequenced adaptive filtering," *Med. Biol. Eng. Comput.*, vol. 56, 2018. https://doi.org/10.1007/s11517-018-1862-8

[17] G. B. Moody, W. E. Muldrow, R. G. Mark, "A noise stress test for arrhythmia detectors," *Computers in Cardiology*, vol. 11, pp. 381–384, 1984. Base: https://physionet.org/content/nstdb/1.0.0/

[18] N. V. Thakor, Y. S. Zhu, "Applications of adaptive filtering to ECG analysis: noise cancellation and arrhythmia detection," *IEEE Trans. Biomed. Eng.*, vol. 38, no. 8, pp. 785–794, 1991.

[19] J. Pan, W. J. Tompkins, "A real-time QRS detection algorithm," *IEEE Trans. Biomed. Eng.*, vol. 32, no. 3, pp. 230–236, 1985. https://doi.org/10.1109/TBME.1985.325532

[20] P. S. Hamilton, W. J. Tompkins, "Quantitative investigation of QRS detection rules using the MIT/BIH arrhythmia database," *IEEE Trans. Biomed. Eng.*, vol. BME-33, no. 12, pp. 1157–1165, 1986.

[21] M. Elgendi, M. Jonkman, F. De Boer, "Frequency bands effects on QRS detection," en *Proc. 3rd Int. Conf. Bio-inspired Systems and Signal Processing (BIOSIGNALS)*, pp. 428–431, 2010.

[22] D. Makowski, T. Pham, Z. J. Lau, et al., "NeuroKit2: A Python toolbox for neurophysiological signal processing," *Behav. Res. Methods*, vol. 53, no. 4, pp. 1689–1696, 2021. https://doi.org/10.3758/s13428-020-01516-y

[23] ANSI/AAMI EC57, *Testing and reporting performance results of cardiac rhythm and ST segment measurement algorithms*. https://webstore.ansi.org/standards/aami/ansiaamiisoec571998r2008

[24] S. Dash, K. H. Chon, S. Lu, E. A. Raeder, "Automatic real time detection of atrial fibrillation," *Ann. Biomed. Eng.*, vol. 37, no. 9, pp. 1701–1709, 2009. https://doi.org/10.1007/s10439-009-9740-z

[25] J. A. Behar, A. A. Rosenberg, I. Weiser-Bitoun, et al., "PhysioZoo: a novel open access platform for heart rate variability analysis of mammalian electrocardiographic data," *Front. Physiol.*, vol. 9, 2018. https://doi.org/10.3389/fphys.2018.01390

[26] A. Petrėnas, V. Marozas, L. Sörnmo, "Low-complexity detection of atrial fibrillation in continuous long-term monitoring," *Comput. Biol. Med.*, vol. 65, pp. 184–191, 2015. https://doi.org/10.1016/j.compbiomed.2015.01.019

[27] D. E. Lake, J. R. Moorman, "Accurate estimation of entropy in very short physiological time series: the problem of atrial fibrillation detection in implanted ventricular devices," *Am. J. Physiol. Heart Circ. Physiol.*, vol. 300, pp. H319–H325, 2011.

[28] Task Force of the ESC and NASPE, "Heart rate variability: standards of measurement, physiological interpretation and clinical use," *Circulation*, vol. 93, pp. 1043–1065, 1996. https://doi.org/10.1161/01.CIR.93.5.1043

[29] F. Shaffer, J. P. Ginsberg, "An overview of heart rate variability metrics and norms," *Front. Public Health*, vol. 5, 258, 2017. https://doi.org/10.3389/fpubh.2017.00258

[30] P. Laguna, G. B. Moody, R. G. Mark, "Power spectral density of unevenly sampled data by least-square analysis: performance and application to heart rate signals," *IEEE Trans. Biomed. Eng.*, vol. 45, no. 6, pp. 698–715, 1998. https://doi.org/10.1109/10.678605

[31] A. Boardman, F. S. Schlindwein, A. P. Rocha, A. Leite, "A study on the optimum order of autoregressive models for heart rate variability," *Physiol. Meas.*, vol. 23, pp. 325–336, 2002.